

YelpZip 리뷰 사기 탐지

최종 보고서

경희대학교 빅크크 (박서현, 이승아, 조서영)

1. 모델링 목표 정의

YelpZip 리뷰 데이터셋(전체 608,458 건)에서 허위(사기) 리뷰를 탐지하는 GNN 모델을 설계·학습한다.

- 기존 머신러닝의 평면적(tabular) 한계 극복
 - 리뷰·유저·식당·키워드 간 상호작용하는 이기종 정보 네트워크(HIN) 구조 채택
- 사기꾼의 위장(Camouflage) 패턴 방어
 - CARE-HAN + CatBoost 를 최종 모델로 채택하여 HIN 기반 고도화를 완료하였다.
- 파이프라인 5 단계 일관성 확보
 - (1) 라벨 정합성 → (2) 밀도 중심 샘플링 → (3) 다축 EDA → (4) 데이터 누수 차단 → (5) 모델 학습

2. 데이터 구성 및 전처리 과정

2-1. 사용 데이터

■ 원본 데이터셋 현황

항목	수치
데이터셋	YelpZip (2013~2014)
전체 리뷰 수	608,458 개
정상 리뷰 (label=1)	528,019 개 (86.8%)
사기 리뷰 (label=-1)	80,439 개 (13.2%)
컬럼	user_id, prod_id, rating, label, date, text, tag

■ 최종 샘플링 결과

구분	수치
최종 리뷰 수	50,950 개
정상 리뷰 (label=0)	38,291 개 (75.2%)
사기 리뷰 (label=1)	12,659 개 (24.8%)
고유 사용자 수	~17,439 명
고유 식당 수	200 개

2-2. 전처리 내용

① 라벨 변환

YelpZip 원본 라벨 체계(-1 사기 / 1 정상) → 프로젝트 규칙(1 사기 / 0 정상)으로 변환.


- 문제: Parquet 재로드 시 이중 변환 → 데이터 오염 발생
- 해결: 로드 시점에 {-1, 1} 여부를 사전 검사하여 미변환 상태일 때만 매핑 적용 (조건부 방어 로직)

② 4 단계 밀도 중심 샘플링 파이프라인

단순 랜덤 추출은 R-U-R-R-P-R 등 핵심 관계를 희박하게 만들어 GNN 학습에 치명적 → 그래프 연결성을 보존하는 밀도 중심 샘플링 채택.

단계	내용	결과
0. 시간 필터링	2013~2014 년 한정 (Concept Drift 방지)	608,458 개 → 311,873 개
1. 상위 200 개 식당	R-P-R 엣지 밀도 확보 (300 개 시도 시 ~17 만 노드 폭증 → 200 개로 정예화)	→ 107,445 개
2. 사기 유저 타겟팅	사기 리뷰 ≥ 1 회 유저(10,108 명)의 모든 리뷰	13,282 개
3. 활성 정상 유저	리뷰 ≥ 3 개 유저(7,331 명)의 리뷰	37,668 개

- 사기 비율 24.8% 유지 근거: GraphSMOTE(WSDM 2021), Weiss & Provost(JAIR 2003), CARE-GNN(CIKM 2020) — 소수 클래스 20~30%가 Recall-F1 에 유리, GNN Over-smoothing 방지
- Loss 가중치: 이중 보정 방지를 위해 pos_weight=8.5 → 3.0 으로 재설정 (Neg/Pos $\approx$ 2.93 기준)



밀도 중심 샘플링 전후 `user_burst_max7d` 분포 비교. 서브그래프에서 사기/정상 간 버스트 비율 차이가 전체 데이터(17.7 배) 대비 37.1 배로 오히려 강하게 보존되어, 샘플링이 사기 탐지 신호를 희석시키지 않았음을 확인하였다.

③ 데이터 누수(Data Leakage) 차단

베이스라인(04) PR-AUC 0.9292 → 누수 제거 후 0.6044 로 보정. 3 중 5 개 누수 식별·제거.


유형	문제	해결
Type A 분리 방식	random_state=42 무작위 분리 → 시간 순서 파괴	유저 단위 랜덤 분할 적용 (동일 유저 리뷰가 같은 파티션에 배치)
Type B 구조적 관계	R-U-R 엣지 → 같은 유저 = 라벨 정보	베이스라인: R-U-R → R-S-R 교체 풀 모델:

	(Transductive Leakage)	라벨 기반 피쳐 제거 후 R-U-R 포함 6 관계 유지
Type C 타깃 인코딩	user_fraud_ratio, is_fraud_user → 전형적 타깃 인코딩	피쳐 완전 제거 → 라벨 미사용 행동 피쳐(user_burst_max7d 등)로 대체

- 노트북별 누수 방지: EDA(02~03) 전 연산을 train 행만으로 제한, global_mean 도 train 평점 평균만 사용

2-3. 파생 변수(Feature) 및 그래프 엣지(Edge) 설계 근거


① 최종 피쳐 구성



버스트 피쳐 종합 분석 시각화. 사기 리뷰어의 시계열 및 버스트 패턴을 매크로(월별)·요일별·마이크로(7 일 윈도우)·협력(주간 고유 계정) 4 개 스케일로 분석하였다.

- 월별 버스트: 사기 리뷰는 연중 균일하지 않고 2014 년 8-9-12 월에 집중 폭증(임계치 671 건 초과) → 평점 조작이 우발적 행동이 아닌 단기 캠페인 형식으로 기획·투입됨을 시사
- 요일 패턴: 화요일(26.5%) 고점, 주말(토·일 22~24%) 저점 → 일반 유저와 정반대 흐름; 사기 조작단이 평일 업무 시간에 조직적으로 작업하는 직업적 행태 암시

- 7 일 윈도우 분포: 사기 유저 대다수가 1 주일에 1~4 개만 작성하고 이탈("Hit-and-Run") → 개별 계정 단위 탐지 회피; 오히려 정상 유저 중 주간 7~9 개 다작 리뷰어 존재
- 협력 버스트: 2014 년 하반기 주간 고유 사기 계정 수가 임계치(139.9 명) 반복 돌파(최대 183 명) → 소수 도배가 아닌 다수 계정의 동시 동원, 조직적 봇넷 타격 구조 실증




텍스트 피처 10 종(글자 수·단어 수·숫자 비율·메뉴 언급·특수문자 비율 등)의 사기/정상 분포 비교 및 Cohen's d 효과 크기. 사기 리뷰는 단어 수(-0.31)·텍스트 길이(-0.31)가 짧은 반면, 감성 점수(+0.22)·TTR(+0.28)이 높아 짧고 긍정적인 문체 패턴이 사기 리뷰의 특징임을 확인하였다.

카테고리	피처	설계 근거
버스트 행동	user_burst_max7d user_burst_ratio	7 일 슬라이딩 윈도우 내 최대 리뷰 수·비율 사기/정상 변별력 약 10 배 (Xie et al. KDD 2012; Rayana & Akoglu KDD 2015)
별점 이탈도	rating_deviation is_cold_start is_early_review	누적 평균 대비 이탈도 (expanding+shift(1)으로 미래 누수 차단) 콜드스타트 NaN → global_mean(3.7) 대체 + 지시 변수 추가 (Rev2, Kumar et al. WSDM 2018)
엔트로피	user_rating_entropy	사기=1 점·5 점 집중 → 낮은 엔트로피; 정상=다양 → 높음 정규화: entropy/log(N); 단일 리뷰 유저 → 중립값 0.5


텍스트	TF-IDF SVD 64 차원 vocab_discrim, kw_*10 개	변별 어휘 300 개 (EDA 어휘 103 개와 독립 선정, 순환 논리 방지) 코사인 유사도 $\geq 0.85 \rightarrow$ R-Sim-R 엣지 생성에도 활용
기타	rating, weekday fraud/normal_intensity	1 점 Pollute / 5 점 Push 전략 포착 요일(주중 사기 비율 높음), 관계별 사기·정상 강도 신호

- 삭제 피쳐: is_dissonant(VADER 역전 $\rightarrow$ 노이즈), user_fraud_ratio / is_fraud_user(타깃 인코딩 누수)



fraud_intensity-normal_intensity 분포(Train 기준). 사기 리뷰는 정상 어휘(normal_intensity)가 0.0에 집중되고, 사기 어휘(fraud_intensity)는 0.3 이상 우측 꼬리가 두터운 양극단 패턴을 보인다. 실제 방문 경험 없이 템플릿 어휘만 사용하는 조작 행태가 수치로 확인되며, 두 지표를 GNN 노드 피쳐로 직접 주입하여 조기 탐지 민감도를 높였다.


② 그래프 엣지(Edge) 설계



연결 중심성 분포 — 임계값 선택 근거. 단어 네트워크의 연결 중심성은 0.0~0.1 구간에 밀집된 전형적인 롱테일(Long-tail) 분포를 보인다. 평균(0.1029, 붉은 점선)은 소수 고중심성 허브 단어에 의해 우측으로 왜곡되어, 이를 임계값으로 사용하면 탐지에 유의미한 중간층 어휘까지 과도하게 제거된다. 이에 극단값의 영향을 받지 않는 70th 백분위(0.0981, 초록

실선)를 컷오프로 채택하여 하위 70% 노이즈는 제거하되 핵심 어휘 풀(상위 30%)은 손실 없이 확보하였다.


Refined Review Word Network (Hubs Removed & Communities Detected)




정제된 리뷰 단어 네트워크 (허브 제거 후 커뮤니티 탐지). 범용 허브 단어 제거 후 커뮤니티별로 파인다이닝(wine-steak-lamb), 캐주얼(burger-quick-cash) 등 식당 유형별 어휘 군집이 확인된다. 이 핵심 어휘를 TF-IDF 사전으로 구축하여 R-Sim-R 엣지 생성 시 복불형 사기 템플릿을 효과적으로 군집화하였다.



사기/정상 리뷰 단어 네트워크 — 고유벡터 중심성 변별력 비교. 사기 리뷰는 'said-ordered-minutes' 등 행동-상황 서술이, 정상 리뷰는 'crunchy-savory-creamy' 등 음식 감각 묘사가 상위를 차지한다. 실제 방문 경험 없이 가짜 서사를 꾸며낸다는 도메인 가설을 네트워크 지표로 실증하였으며, 이 변별 어휘를 TF-IDF 사전으로 구성하여 GNN 텍스트 피처의 노이즈를 최소화하였다.




귀무가설 분포 시각화. 라벨을 무작위로 섞은 100 회 순열 검정(Permutation Test)에서 귀무가설 분포(회색)는 0.018 부근에 밀집된 반면, 실제 관측값(0.03325, 붉은 점선)은 귀무분포의 우측 끝을 완전히 벗어나 있다. 100 회 중 관측값을 초과한 경우가 단 한 번도 없어 $p\text{-value} = 0.0000$ 을 달성하였다. 이는 사기/정상 리뷰 간 단어 네트워크 중심성 차이가 우연이 아닌 구조적 언어 패턴의 차이임을 통계적으로 완벽히 입증하며, 앞서 추출한 텍스트 기반 피처의 타당성과 변별력을 확증한다.




별점 분포 vs 사기 비율(Fraud Ratio). 사기 비율은 1 점(~60%)과 5 점(~30%)에서 급등하고 3 점에서 최저를 찍는 U자형 곡선을 형성한다. 1 점 테러(경쟁 식당 공격)와 5 점 부스팅(의뢰 식당 조작)이라는 두 가지 목적에 집중된 조작 패턴이 확인되며, 별점을 GNN 노드 피처로 채택하여 극단 평점 노드의 초기 의심도를 높이는 근거로 활용하였다.

오태	코드	정의 및 설계 근거
같은 유저	R-U-R	동일 user_id 리뷰 간 연결 — 계정 반복 사기 패턴 포착
같은 시기	R-T-R	동일 prod_id + 동일 week_bin (MAX_RTR=4) — 캠페인 집중 공격 탐지

같은 별점-식당	R-S-R	동일 prod_id + 동일 rating — 베이스라인 누수 회피용
의심 패턴	R-P-R	짧고 + 메뉴 언급 없고 + 긍정 단어 많음 → suspicious=1 (MAX_RPR=5) Soft Discount 로 과도한 전파 제어
같은 식당	R-B-R	동일 prod_id 리뷰 간 연결 — 광역 캠페인 탐지
텍스트 유사도	R-Sim-R	변별 어휘 300 개 TF-IDF, 코사인 ≥ 0.85 2,000 개 청크 분할 처리; Chi-square + Cramér's V 로 유효성 검증




리뷰 간 텍스트 유사도 분포 및 R-TextSim-R 엣지 유형 분포. 코사인 유사도는 0.0~0.3 구간에 집중되어 임계값 0.85 가 복불 수준의 템플릿 공유만 정밀 타겟팅하는 보수적 기준임을 확인하였다. Fraud-Fraud 엣지 관측값(43,277 건)이 기댓값(9,867 건) 대비 4.3 배 폭증하고(Cramér's V = 0.6808), Normal-Normal 은 기댓값 이하로 나타나 사기 조작단의 조직적 템플릿 재사용을 통계적으로 입증한다.




누적 평점 편차를 통한 여론 조작 패턴. 시간 순서를 반영한 누적 평균(expanding+shift(1)) 기준으로 계산한 rating_deviation 의 박스플롯에서, 사기 리뷰(1)의 중앙값과 75th 백분위수가 정상 리뷰(0) 대비 뚜렷하게 상향 이동해 있다. 사기 조작단이 기존 여론(누적 평균 평점)과

무관하게 극단적 별점을 투입하여 흐름을 의도적으로 이탈시킨다는 여론 조작 패턴을 시계열 기반으로 입증한다. 미래 정보를 참조하지 않는 Time-aware 설계(데이터 누수 차단)이므로 피쳐로서의 신뢰성도 동시에 확보된다.



정규화 평점 엔트로피 분포 (복수 리뷰 유저 기준). 정상 유저(파란색)는 0.4~0.7 구간에 자연스러운 평점 다양성을 보이는 반면, 사기 유저(주황색)는 0.0(단일 별점 반복)과 1.0(1.5 점 양극단) 부근에만 분포하는 극단적 패턴을 보인다. 전체 밀도가 낮은 것은 다중 계정 Hit-and-Run 전략(계정당 리뷰 최소화)을 반영하며, 이를 GNN 노드 피쳐로 채택하여 기계적 조작 계정을 조기 식별한다.

- EDA ① 버스트: 협력 임계값 139.9 명 초과 시 조직적 공모 판정 (2014-12-08 주간 최대 183 명 동시 활동)
- EDA ② 텍스트 네트워크: 사기 군집 계수 0.541 vs 정상 0.112(5 배) → 사기는 템플릿 기반 어휘 세트 사용 확인
- EDA ③ 별점: 1 점(32.4%, Pollute) / 5 점(15.6%, Push) — 전체 사기율 13.2% 대비 1 점 약 2.5 배



샘플 리뷰 그래프(R-U-R-R-T-R-R-P-R 엣지), 차수 분포(사기 평균 3.22 vs 정상 0.52), 동질성(Homophily) 지표(실제 FF 비율 vs 랜덤 기대값), 차수 분위별 사기율(Q5: 64.1%), 의심 패턴 혼동 행렬. 사기 노드는 정상 노드 대비 엣지 연결이 6 배 이상 많고, 상위 차수 구간일수록 사기율이 급증하는 구조적 패턴이 나타난다.

3. 모델 선택 이유와 적용 과정

3-1. 선택한 모델

최종 모델: CARE-HAN + CatBoost (06_HIN_CARE_Model.ipynb)

- 3 종 노드 HIN(Review + User + Restaurant) 기반 이중 정보 네트워크
- Trust-Aware CARE 게이트 + Semantic Attention 으로 위장 노드 신호 억제
- GNN 임베딩(128 차원) + 원시 피쳐(78 차원) = 206 차원 CatBoost 하이브리드

3-2. 모델 선택 이유

① 아키텍처 진화 경로

단계	모델	한계 → 개선
예선	PC-GNN	rating_norm 1 차원 → 72 차원(행동 피쳐 8 + TF-IDF SVD 64) / 엣지 3 종 → 4 종(R-U-R-S-R-R-P-R-R-Sim-R) / inter-relation

		attention + FocalLoss + CosineAnnealingLR 적용
최종	CARE-HAN + CatBoost	동질 그래프(Review 노드만) 한계 → 3 종 노드 HIN(Review+User+Restaurant)으로 확장 / Trust-Aware CARE 게이트로 위장 이웃 억제 / GNN 임베딩 + 원시 피쳐 CatBoost 하이브리드 → PR-AUC 0.8634 → 0.9279

② 최종 모델 선택 근거 (CARE-HAN+CatBoost vs PC-GNN)

첫째, 노드 구조의 확장. PC-GNN 은 Review 노드만 존재하는 동질 그래프로, 유저·식당의 맥락이 피쳐로만 압축된다. CARE-HAN 은 Review(78 차원)·User(12 차원)·Restaurant(6 차원) 3 종 노드가 직접 메시지 패싱에 참여하는 이중 정보 네트워크(HIN)로, 유저 행동 이력과 식당 특성이 그래프 구조로 직접 반영된다.

둘째, 위장 노드 방어 메커니즘. PC-GNN 의 Chooser 어텐션이 이웃별 중요도를 학습하는 데 그치는 반면, CARE-HAN 의 Trust-Aware CARE 게이트는 sim_gate(임베딩 유사도)와 trust_j(노드 신뢰도)를 곱해 위장 정상 노드의 메시지를 이중 차단한다. 유저 신뢰도(trust_score)는 활동 기간과 리뷰 수로 정의되어 임시 계정의 신호를 억제한다.

셋째, U-collude-U 공모 엣지 도입. PC-GNN 의 R-U-R 은 동일 유저의 리뷰를 간접 연결하는 데 그치나, CARE-HAN 의 U-collude-U 는 같은 식당에 7 일 이내 리뷰를 남긴 서로 다른 유저를 직접 연결한다. 이는 02 버스트 분석의 마이크로 버스트 패턴(7 일 윈도우)에 근거하며, 조직적 공모 관계를 그래프 구조로 직접 모델링한다.

넷째, CatBoost 하이브리드 앙상블. GNN 임베딩(128 차원, 그래프 구조 신호) + 원시 피쳐(78 차원, 개별 행동 이상 신호) = 206 차원을 CatBoost 에 입력하여 두 모델이 서로 보완한다. GNN 만으로 놓치는 고립 사기꾼은 원시 피쳐가, 원시 피쳐가 평범해 보이는 공모자는 GNN 구조가 탐지한다. CARE-HAN GNN 단독 PR-AUC 0.8221 → 하이브리드 최종 0.9279 로 +0.1058 향상.

3-3. 모델 적용 과정

① 피쳐 입력

모델	차원	구성
04_Baseline	78 차원	04_Baseline RGCN: rating_norm 1 차원 / 엣지: R-S-R + R-Sim-R

		04_Baseline PC-GNN: 행동 7 개 / 엣지 R-U-R + R-P-R + R-T-R
05_1_PCGNN	72 차원	행동 피쳐 8 개 + TF-IDF SVD 64 차원 / 엣지: R-U-R + R-S-R + R-P-R + R-Sim-R
06_HIN_CARE	리뷰 78 유저 12 식당 6	리뷰: 기본 수치 14 + TF-IDF SVD 64 / 유저: user_review_count, user_fraud_ratio, user_avg_rating, activity_span, user_burst_max7d, norm_rating_entropy, trust_score 등 12 개 / 식당: prod_avg_rating, prod_fraud_ratio, prod_review_count 등 6 개 / 엣지: R-Sim-R + U-writes-R + P-about-R + U-collude-U

② 학습 설정

- 손실 함수: 04(ReviewRGCN) CrossEntropyLoss + 클래스 가중치 / 05_1(PC-GNN) FocalLoss ($\gamma=2.0$) + 클래스 가중치 / 06(CARE-HAN) 가중 CrossEntropyLoss (Fraud 가중치 3.02)
- 데이터 분할: 04-06 시간 기반 분할 (기준일 2014-06-28, Train 57.7%/Val 14.4%/Test 27.9%) / 05_1 유저 단위 분할 (Train 60%/Val 20%/Test 20% — R-U-R 누수 방지)
- CARE-HAN 전이적(Transductive) 학습: Train/Val/Test 노드 모두 메시지 패싱 참여 (레이블은 Train 손실에만 사용) — Test 노드도 그래프 구조에서 정보를 받아 임베딩 품질 향상

4. 모델 성능 평가 & 결과 해석

4-1. 평가 지표

사기 탐지 특성상 클래스 불균형과 Precision-Recall 트레이드오프를 동시에 포착해야 하므로 두 가지 주요 지표를 병행 사용.


지표	정의	선택 이유
PR-AUC (Precision-Recall AUC)	Precision-Recall 곡선 아래 면적 (1 에 가까울수록 우수)	클래스 불균형 환경에서 ROC-AUC 보다 사기 탐지 성능을 정확하게 반영 소수 클래스(사기 리뷰)의 탐지 능력을 직접 측정

Macro F1 (Macro-averaged F1)	클래스별 F1 의 단순 평균 (0~1, 높을수록 우수)	정상·사기 클래스에 동등한 가중치 부여 Precision 과 Recall 의 조화 평균으로 한쪽 편향 탐지 가능
------------------------------	--------------------------------	--


- 보조 지표: Precision, Recall, ROC-AUC (Macro F1·PR-AUC 해석의 참고 맥락으로 활용)
- 평가 기준: 04:06 시간 기반 분할 (기준일 2014-06-28) / 05_1 유저 단위 분할 (R-U-R 누수 방지)

4-2. 모델 성능 결과


최종 모델 CARE-HAN+CatBoost 는 PR-AUC 0.9279, Macro F1 0.9136 을 달성하여 **베이스라인 대비 PR-AUC +53.6% 향상**되었다. 실제 사기 리뷰 2,532 건 중 2,404 건을 정확히 탐지하여 Recall 94.9%를 달성하였으며, Precision 80.9%로 미탐(False Negative)과 오탐(False Positive)을 동시에 최소화하였다. GNN 단독(PR-AUC 0.8221) 대비 CatBoost 하이브리드가 +0.1058 추가 향상하여 그래프 구조 신호와 개별 행동 신호의 상호 보완 효과를 실증하였다.



CARE-HAN GNN 100 에폭 학습 손실(좌) 및 검증 성능(우) 추이. 약 40 에폭 이후 손실이 수렴하며 Val PR-AUC ~0.84 에서 안정.



CARE-HAN GNN 단독 성능(PR-AUC 0.8221, Macro F1 0.7417) 및 학습 곡선. 손실은 약 40 에폭 이후 수렴하며 Val PR-AUC 는 ~0.84 에서 안정적으로 유지되었다. 혼동 행렬 기준 정상 5,506 건·사기 2,311 건을 정확히 분류하였다.



CARE-HAN GNN 단독 vs CARE-HAN+CatBoost 하이브리드 성능 비교(PR-AUC 0.8221 → 0.9279). CatBoost 피쳐 중요도 상위 20 개 중 GNN 임베딩 피쳐가 다수 포함되어, 그래프 구조 신호가 실질적인 예측력을 가짐을 확인하였다. 최종 혼동 행렬 기준 정상 7,092 건·사기 2,404 건 정확 예측.

아키텍처 단계별 성능 변화

모델 버전	PR-AUC	Macro F1	주요 변경사항
PC-GNN(예선)	안정화	안정화	Picker(동적 샘플링) + Chooser(어텐션) 도입, 클래스 불균형 해소 및 위장 이웃 필터링
CARE-HAN GNN 단독	0.8221	0.7417	3 종 노드 HIN(Review+User+Restaurant) + U-collude-U 엣지 도입 / Trust-Aware CARE 게이트 + Semantic Attention / GNN 단독 — CatBoost 미결합
CARE-HAN +CatBoost (최종)	0.9279	0.9136	GNN 임베딩(128 차원) + 원시 피쳐(78 차원) = 206 차원 CatBoost 하이브리드 / GNN 단독 대비 PR-AUC +0.1058 향상 / 베이스라인(0.6041) 대비 최종(0.9279) PR-AUC +53.6%

4-3. 결과 해석

① 누수 보정의 의미


- PR-AUC 0.9292 → 0.6044: 겉보기 고성능이 데이터 누수에서 기인했음을 실증
- 누수 제거 후 0.6044 는 모델이 학습해야 할 실제 난이도를 반영한 신뢰성 있는 출발점
- 3 종 누수 각각의 기여: 무작위 분리(−0.0186), R-U-R 엣지(−0.1411), 타깃 인코딩(−0.1651) 순으로 영향

② 아키텍처 진화 해석

ReviewRGCN 베이스라인의 한계를 극복하기 위해 PC-GNN(05_1_PCGNN)을 예선 파이프라인으로 채택하였으며, 이후 3 종 노드 HIN 기반 CARE-HAN+CatBoost(06_HIN_CARE)로 최종 고도화하였다. 각 단계의 주요 설계 변경과 고도화 효과는 아래 표와 같다.

구분	04_Baseline (ReviewRGCN)	05_1_PCGNN (예선 모델)	06_HIN_CARE (최종)

노드 구조	Review 1 종 (동질그래프)	Review 1 종 (동질그래프)	Review+User+Restaurant 3 종 (HIN)
입력 피쳐	rating_norm 1 차원	72 차원 (행동 8 + TF-IDF SVD 64)	리뷰 78 차원+유저 12 차원+식당 6 차원
엣지 관계	2 종 (R-S-R, R-Sim-R)	4 종 (R-U-R, R-S-R, R-P-R, R-Sim-R)	4 종 (R-Sim-R, U-writes-R, P-about-R, U-collude-U)
집계 방식	RGCN (관계별 고정 가중치)	Chooser 어텐션 (위장 이웃 억제)	Trust-Aware CARE 게이트 + Semantic Attention
학습 최적화	CrossEntropyLoss + 클래스 가중치	FocalLoss + Picker 샘플링 + CosineAnnealingLR	가중 CrossEntropyLoss + CatBoost 하이브리드
최종 성능	PR-AUC 0.6041 / Macro F1 0.5896	PR-AUC 0.8634 / Macro F1 0.7701	PR-AUC 0.9279 / Macro F1 0.9136




세 모델의 단계별 PR-AUC·Macro F1 개선 추이. 04 ReviewRGCN(0.60/0.59) → 05 PC-GNN(0.86/0.77, +42.9%) → 06+ CARE-HAN+CatBoost(0.93/0.91, +7.5%) 순으로 단계적으로

향상되었다.

③ 핵심 탐지 신호 해석

탐지 신호	수치	해석
버스트 피쳐 변별력	약 10 배	user_burst_max7d 가 단일 노드 피쳐 중 가장 강력한 사기 탐지력 보유
텍스트 군집 계수	사기 0.541 vs 정상 0.112 (약 5 배)	사기 리뷰는 어휘를 세트로 묶어 쓰는 템플릿/스크립트 구조 실증
별점 이탈 패턴	1 점 사기율 32.4% (전체 13.2%의 2.5 배)	1 점 Pollute(경쟁사 폄훼) 전략이 가장 지배적인 사기 유형
R-Sim-R 동질 연결	Fraud-Fraud 연결 통계적 유의 (Chi-square 검증)	유사 텍스트 리뷰 간 엣지가 사기 클러스터를 구조적으로 포착

- 다층 신호(버스트·텍스트·별점·엣지)가 CARE-HAN 의 Semantic Attention 을 통해 통합됨으로써 단일 피쳐 의존보다 높은 사후 해석력과 일반화 성능 확보



GNN·CatBoost 의 Train-Test PR-AUC 갭(각 0.067, 0.071) 막대 비교 및 예측 확률 분포.

Train 과 Test 의 예측 분포가 일치하여 일반화 양호 상태임을 확인하였다. Val-Test 갭 0.0148 로 과적합 없음(기준 0.05 이내)으로 판정된다.

5. 모델 기반 인사이트 및 활용 방안

5-1. 단계별 성능 기여 분석

단계별 모델 성능 향상의 원인을 피처 설계와 모델 구조 기여로 분해하여 분석하였다.

단계	설명	PR-AUC	Macro F1
단계 1 (베이스라인)	RGCN + rating_norm 1 차원	0.6041	0.5896
단계 2 (피처·모델 기여)	PC-GNN + 행동 피처 8 개 + TF-IDF SVD 64 차원 (4 종 엣지, Chooser 어텐션, FocalLoss)	0.8634	0.7701
단계 3 (HIN·하이브리드 기여)	CARE-HAN + CatBoost (3 종 노드 HIN + 하이브리드 앙상블)	0.9279	0.9136

▲ 단계 1→2: 피처 설계 + 모델 구조 기여

rating_norm 1 차원에서 행동 피처 8 개 + TF-IDF SVD 64 차원(총 72 차원)으로 피처를 확장하고, Chooser 어텐션·FocalLoss·R-U-R 엣지 추가 등 모델 구조를 동시에 고도화하였다. PR-AUC 가 0.6041 → 0.8634 로 +0.2593 향상되었으며, user_burst_max7d(단기 집중 작성), rating_deviation(별점 이탈도) 등 EDA 기반 행동 피처와 R-U-R 엣지를 통한 공모 패턴 탐지가 주요 기여 요인이다.

▲ 단계 2→3: HIN 구조 + 하이브리드 앙상블 기여

동질 그래프(Review 1 종)에서 3 종 노드 HIN(Review + User + Restaurant)으로 확장하고, Trust-Aware CARE 게이트·Semantic Attention·U-collude-U 엣지·CatBoost 하이브리드를 적용하였다. PR-AUC 가 0.8634 → 0.9279 로 +0.0645 추가 향상되었으며, GNN 임베딩(128 차원 구조 신호)과 원시 피처(78 차원 행동 신호)의 상호 보완 효과가 수치로 확인된다.

5-2. 핵심 결론

- **단계 1→2 기여 (피처 설계 + 모델 구조):** EDA 에서 발굴한 행동 피처와 GNN 구조 개선이 결합하여 전체 향상폭(+0.3238)의 약 80%에 해당하는 +0.2593 을 달성하였다. R-U-R 추가로 조직적 공모 패턴을 직접 탐지하고, Chooser 어텐션으로 위장 정상 이웃의 영향을 억제한 것이 핵심 원인이다.
- **단계 2→3 기여 (HIN + 하이브리드):** EDA 기반 피처·동질 그래프만으로는 포착하기 어려운 유저·식당 맥락 정보와 조직적 공모 네트워크를 HIN 구조가 추가로 탐지한다. GNN 단독(PR-AUC 0.8221) 대비 CatBoost 하이브리드 최종(0.9279)으로 +0.1058 향상되어, 그래프 구조 신호와 개별 행동 신호가 상호 보완적으로 작동함을 실증하였다.
- **최종 결론:** EDA 기반 피처 설계, GNN 모델 구조 고도화, HIN 확장 및 하이브리드 앙상블이 단계적으로 누적되어 베이스라인(PR-AUC 0.6041) 대비 최종 모델(PR-AUC 0.9279)의 +0.3238 향상을 달성하였다.